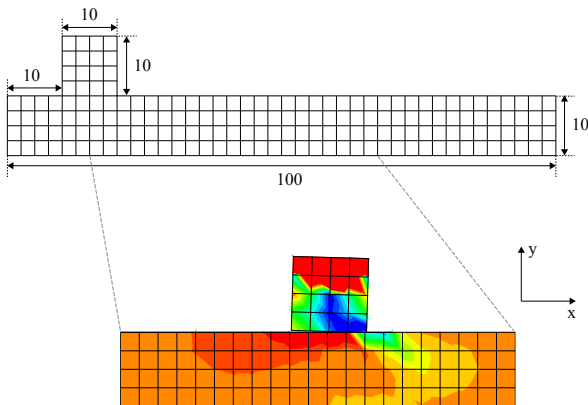


# Data-assimilaatio kitkamallissa


Tom Gustafsson

5. syyskuuta 2012

- Lähtökohtana: Onnistuuko huonosti tunnettujen parametrien ennustaminen elastisesta kitkamallista *data-assimilaation* tarjoamien keinojen avulla?




- Alkutila: Painin, laatta
- Reunaehdot



- Abaqus/Standard 6.12-1, simulaatiot CSC:n koneella


- Vaihe 1: 5 kN voima




- Vaihe 2: Yläreunan siirto 70 cm oikealle

# Simulaation vaiheet: Yläreunan siirtymä


- Siirto reunaehdolla, ns. "hidas siirtymä"



# Simulaation vaiheet: Yläreunan siirtymä 2




- Pyritään estimoimaan kitkakerroin  $\mu$
- Etukäteistietona  $x$ -suuntaiset jännitykset mittapisteissä ( $\sim$  venymäliuskamittaus)



- Mittadata synteettistä

# Synteettisen mittadatan generointi


- Minimoidaan inversiorikosta → mittadata tiheämmästä verkosta



- Miten verrata tiheämmän ja harvemman verkon antamia jännityksiä?



# Synteettisen mittadatan generointi 2




- Estimoitava suure: Kitkakerroin  $\mu = 0,5$
- Etukäteistieto:  $x$ -suuntaiset jännitykset mittapisteissä
- *Data-assimilaatio*

- Pohjimmiltaan havaintojen ja mallin tuotaman informaation yhteensulauttamista
- Perinteisiä sovelluskohteita: Säähavaintomallit, valtamerimallit
- Data-assimilaation menetelmiä
  - 3DVar, 4DVar
  - Kalman Filter, Extended-, Ensemble-, ...
  - ...
- Tässä työssä *Ensemble Smoother*, eli ES
- Perustuu samaan ideaan kuin *Ensemble Kalman Filter*, eli EnKF

- Systeemin (todellinen) tila  $\boldsymbol{\psi}^t \in \mathbb{R}^N$
- Mittaus  $\boldsymbol{d} \in \mathbb{R}^M$ 
  - Ei tarkka
  - Suhde tilaan  $\boldsymbol{d} = \mathbf{M}\boldsymbol{\psi}^t + \boldsymbol{\epsilon}$
  - Mittamatriisi  $\mathbf{M} \in \mathbb{R}^{M \times N}$
  - Virhe  $\boldsymbol{\epsilon} \sim \mathcal{N}_M(0, \boldsymbol{\Sigma})$
  - Kovarianssimatriisi  $\boldsymbol{\Sigma} \in \mathbb{R}^{M \times M}$
- Estimoitu tila  $\boldsymbol{\psi}^f \in \mathbb{R}^N$ 
  - Aluksi esim. mittauksien perusteella

# Data-assimilaatio, esimerkki

$$N = M = 2, \mathbf{M} = \mathbf{I}, \mathbf{\Sigma} = \sigma \mathbf{I}$$




- Todellinen tila  $\psi^t$  muuttuu ajan kuluessa
- Malli estimaatin aikakehityksestä:

$$\psi_{t+\Delta t}^f = \psi_t^f + \int_t^{t+\Delta t} \mathbf{G}(\psi_t^f, t) dt$$

- Malli epätäydellinen, eli estimaatin virhe kasvaa aikakehitettäessä

# Data-assimilaatio, esimerkki 2



- Tulkitaan normaalijakauma todennäköisyysfunktiona  $f(\psi, t)$
- Tällöin  $f$ :n aikakehitystä kuvaa *Fokker-Planck* -yhtälö

$$\frac{\partial f}{\partial t} + \sum_{i=1}^N \frac{\partial (G_i f)}{\partial \psi_i} = \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \frac{\partial^2 (Q_{ij} f)}{\partial \psi_i \partial \psi_j}$$


- *Hurja*, mutta ei niin hurja miltä näyttää (sij.  $\mathbf{G} = \mathbf{0}$  ja  $\mathbf{Q} = \mathbf{I}$ )
- Yleinen tapaus ei ratkea analyyttisesti  $\rightarrow$  EnKF




- Idea: Otetaan  $n$ -kappaletta realisaatioita alkutilan normaalijakaumasta
- Aikakehitetään näin saadun *kokoelman* jokaista tilaa erikseen operaattorin  $\mathbf{G}$  avulla
- Etu: Estimaatin kovarianssimatriisia ei tarvitse aikakehittää (raskasta), koska sitä voidaan approksimoida lausekkeella

$$\Sigma \approx \frac{1}{n-1} \sum_{j=1}^n \left( \psi_j^f - \overline{\psi^f} \right) \left( \psi_j^f - \overline{\psi^f} \right)^T$$

# Ensemble Kalman Filter, esimerkki




# Ensemble Kalman Filter, esimerkki jatkuu




- Tyypillisesti mittadataa muulloinkin, kuin alkuhetkellä
- Analyysiongelma: *Miten yhdistää optimaalisesti mallin ennuste  $\psi^f$  ja uusi mittaus  $d$ ?*


# Ensemble Kalman Filter, analyysiongelma 2



# Ensemble Kalman Filter, analyysiongelma 3



# Ensemble Kalman Filter, analyysiongelma 4



- *Analysoitu tila*  $\psi^a = \psi^f + K (d - \psi^f)$

- Jos varianssit samat,  $K = \frac{1}{2}$
- Tässä tapauksessa

$$K = \frac{\sigma_\psi}{\sigma_\psi + \sigma_d}$$

- Yleisesti

$$\mathbf{K} = \mathbf{\Sigma}_\psi (\mathbf{\Sigma}_\psi + \mathbf{\Sigma}_d)^{-1}$$

- Jos lisätään vielä mahdollisuus  $N > M$ , niin

$$\psi^a = \psi^f + \mathbf{\Sigma}_\psi \mathbf{M}^T (\mathbf{\Sigma}_d + \mathbf{M} \mathbf{\Sigma}_\psi \mathbf{M}^T)^{-1} (d - \mathbf{M} \psi^f)$$




- Jatketaan tilaa huonosti tunnetuilla parametreilla  $\alpha$

$$\hat{\psi}^f = (\psi^f, \alpha)^T$$

- Karsitaan lisätyt parametrit vertailuista mitattujen arvojen kanssa muokkaamalla mittamatriisia
- → Estimoitavat parametrit loksahtavat kohdalleen automaattisesti!

# Ensemble Kalman Filter, yhteenveto




- Alussa ei jännityksiä, joten alkutilan määrää ainoastaan  $\mu_0 = 0,6$
- Oletetaan jokin virhe; tässä  $\sigma_0 = 0,1$  (myös mittavirheen keskihajonta)
- Päätetään kokoelman koko, esim.  $n = 200$
- Generoidaan alkukokoelma jakaumasta  $\mathcal{N}(\mu_0, \sigma_0^2)$
- Alkukokoelman yksittäinen tila muotoa



$$\psi_j = (\underbrace{0, 0, \dots, 0, 0}_{N \text{ kpl}}, \mu_0 + \epsilon)^T, \quad j = 1, \dots, n$$

- Mitta"hetket": Yläreunan siirtymä  $\Delta x = 7, 14, 21, \dots, 70$
- Simuloidaan seuraavaan mittahetkeen asti ja yhteensulautetaan mittaus ja kokoelma  $\Rightarrow$  kitkakertoimen estimaatti
- Mittahetkiä 10, estimaatteja 10



# Simulointi kuvina




# Tuloksia, ilman mallivirhettä (20, 200)




# Tuloksia, mallivirheellä (200, 1000)



# Kokoelman koon vaikutus, keskiarvo (2-6-10)



# Kokoelman koon vaikutus, kokoelman hajonta (2-6-10)





# Kokoelman koon vaikutus, peräkkäisten analyysien hajonta (2-6-10)

