


Data assimilation in an elastic friction model

Tom Gustafsson


20. September 2012

The problem

- Can we estimate weakly known parameters from a simple friction model by using tools of data assimilation?




- Initial setting: Block, surface
- Boundary conditions



- Abaqus/Standard 6.12-1, simulations on CSC

Steps of the simulation


- Step 1: 5 kN force acting downwards




- Step 2: Displacement of block's upper boundary by 70 cm to the right

Steps of the simulation: Displacement of the block

- Done by using boundary conditions. Thus, a "slow displacement"




Steps of the simulation: Displacement of the block, 2





Inversion problem

- Attempting to estimate friction coefficient μ
- As *a priori* knowledge: x -directional stress in chosen measurement points
(\sim strain gauge)



Ennen kuin jatketaan



- Useampiulotteisen normaalijakauman karakterisoi kovarianssimatriisi Σ
- $\mathcal{N}_k(\mu_0, \Sigma)$, jossa $\Sigma \in \mathbb{R}^{k \times k}$
- Neliömatriisi, diagonaalilla varianssit eri dimensioissa
- Muut alkiot kertovat dimensioiden välisen kovarianssin

- Pohjimmiltaan havaintojen ja mallin tuotaman informaation yhteensulauttamista
- Perinteisiä sovelluskohteita: Säähavaintomallit, valtamerimallit
- Data-assimilaation menetelmiä
 - 3DVar, 4DVar
 - Kalman Filter, Extended-, Ensemble-, ...
 - ...
- Tässä työssä *Ensemble Kalman Filter*, eli EnKF

- Systeemin (todellinen) tila $\psi^t \in \mathbb{R}^N$
- Mittaus $\mathbf{d} \in \mathbb{R}^M$
 - Ei tarkka
 - Suhde tilaan $\mathbf{d} = \mathbf{M}\psi^t + \epsilon$
 - Mittamatriisi $\mathbf{M} \in \mathbb{R}^{M \times N}$
 - Virhe $\epsilon \sim \mathcal{N}_M(0, \mathbf{\Sigma})$
 - Kovarianssimatriisi $\mathbf{\Sigma} \in \mathbb{R}^{M \times M}$
- Ennustettu tila $\psi^f \in \mathbb{R}^N$
 - Aluksi esim. mittauksien perusteella

- Todellinen tila ψ^t muuttuu ajan kuluessa
- Systeemin malli

$$\dot{\psi} = \mathbf{G}(\psi, t)$$


- Aikakehitys:

$$\psi_{t+\Delta t}^f = \psi_t^f + \int_t^{t+\Delta t} \mathbf{G}(\psi, t) dt$$


- Malli epätäydellinen, eli ennusteen virhe kasvaa aikakehitettäessä
- Virheen kasvua kuvaa kovarianssimatriisi \mathbf{Q}

Data-assimilaatio, esimerkki

$$N = M = 2, \mathbf{M} = \mathbf{I}, \mathbf{\Sigma} = \sigma \mathbf{I}$$



Data-assimilaatio, esimerkki 2



- Tulkitaan normaalijakauma todennäköisyysfunktiona $f(\psi, t)$
- Tällöin f :n aikakehitystä kuvaa *Fokker-Planck* -yhtälö


$$\frac{\partial f}{\partial t} + \sum_{i=1}^N \frac{\partial (G_i f)}{\partial \psi_i} = \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \frac{\partial^2 (Q_{ij} f)}{\partial \psi_i \partial \psi_j}$$

- Yleinen tapaus ei ratkea analyyttisesti \rightarrow EnKF


- Idea: Otetaan n -kappaletta realisaatioita alkutilan normaalijakaumasta (\Rightarrow kokoelma)
- Aikakehitetään näin saadun *kokoelman* jokaista tilaa erikseen operaattorin \mathbf{G} avulla
- Tällöin ennusteen kovarianssimatriisia voidaan approksimoida lausekkeella

$$\mathbf{\Sigma} \approx \frac{1}{n-1} \sum_{j=1}^n \left(\psi_j^f - \overline{\psi^f} \right) \left(\psi_j^f - \overline{\psi^f} \right)^T$$

Ensemble Kalman Filter, esimerkki

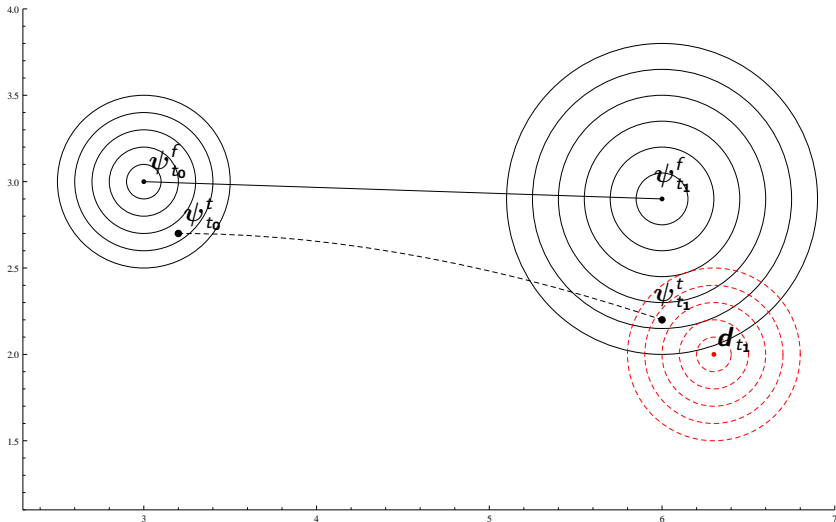


Ensemble Kalman Filter, esimerkki jatkuu




- Tyypillisesti systeemistä saadaan mittadataa mittahetkillä t_1, t_2, t_3, \dots
- Analyysiongelma: *Miten yhdistää optimaalisesti mallin ennuste ψ^f ja uusi mittaus d ?*

Ensemble Kalman Filter, analyysiongelma 2



Ensemble Kalman Filter, analyysiongelma 3



- *Analysoitu tila* $\psi^a = \psi^f + K (d - \psi^f)$

- Jos varianssit samat, $K = \frac{1}{2}$
- Tässä tapauksessa

$$K = \frac{\sigma_\psi}{\sigma_\psi + \sigma_d}$$

- Yleisesti

$$\mathbf{K} = \mathbf{\Sigma}_\psi (\mathbf{\Sigma}_\psi + \mathbf{\Sigma}_d)^{-1}$$

- *Analysoitu tila* $\psi^a = \psi^f + K (d - \psi^f)$

- Jos varianssit samat, $K = \frac{1}{2}$
- Tässä tapauksessa

$$K = \frac{\sigma_\psi}{\sigma_\psi + \sigma_d}$$

- Yleisesti

$$\mathbf{K} = \mathbf{\Sigma}_\psi (\mathbf{\Sigma}_\psi + \mathbf{\Sigma}_d)^{-1}$$

- Jos lisätään vielä mahdollisuus $N > M$, niin

$$\psi^a = \psi^f + \mathbf{\Sigma}_\psi \mathbf{M}^T (\mathbf{\Sigma}_d + \mathbf{M} \mathbf{\Sigma}_\psi \mathbf{M}^T)^{-1} (d - \mathbf{M} \psi^f)$$

- Nyt malli on


$$\dot{\psi} = \mathbf{G}(\psi, t; \alpha)$$

- Käytännössä jatketaan tilaa parametreilla α


$$\hat{\psi}^f = \left(\psi^f, \alpha \right)^T$$

- Karsitaan lisätyt parametrit vertailuista mitattujen arvojen kanssa muokkaamalla mittamatriisia
- → Estimoitavat parametrit loksahtavat kohdalleen ratkaistaessa analyysiongelman

Ensemble Kalman Filter, yhteenveto



- Malli



- Estimoitava parametri μ
- Määritellään tilaksi

$$\psi = (\sigma_x^1, \sigma_x^2, \sigma_x^3, \dots, \sigma_x^N, \mu)^T$$

- Alussa ei kosketusta \Rightarrow jännitykset nolliä
- Alkutilan määrää ainoastaan siis μ_0


- Tarvitaan
 - Alkuarvaus $\mu_0 = 0,6$
 - Alkuarvauksen virhe $\sigma_0 = 0,1$
 - Kokoelman koko $n = 200$
 - Alkukokoelma jakaumasta $\mathcal{N}(\mu_0, \sigma_0^2)$
- Alkukokoelman yksittäinen tila on siis muotoa

$$\psi_j = \underbrace{(0, 0, \dots, 0, 0)}_{N \text{ kpl}}, \mu_0 + \epsilon)^T, \quad j = 1, \dots, n$$

- Mitta "hetket": Yläreunan siirtymät $\Delta x = 7, 14, 21, \dots, 70$
- Mittadata synteettisesti


Synteettisen mittadatan generointi

- Minimoidaan inversiorikosta → mittadata tiheämmästä verkosta




- Miten verrata tiheämmän ja harvemman verkon antamia jännityksiä?


Synteettisen mittadatan generointi 2



Tuloksia, $Q = 0$




$n = 20$




$n = 200$

Tuloksia, mallivirheen vaikutus, $n = 200$




$Q = 0$




$Q = l\sigma$


Kokoelman koon vaikutus, keskiarvo

Punainen: $\Delta x = 70$, sininen: $\Delta x = 42$, vihreä: $\Delta x = 14$





Peräkkäisten analyysien varianssi



Kysymyksiä?